

Zárthelyi dolgozat feladatok

(akik írtak ZH1-t)

Klasszifikációs feladat

- Egy olyan datasettel dolgoztunk, a **Telco Customer Churn** adatállománnyal – amit gyakran használunk gépi tanulási feladatokban. A telefontársaság szeretné előrejelezni a lemorzsolódást (churn), vagyis a hűségidő lejárta után kik fogják elhagyni a telco és átmenni a konkurenciához. Független változók rövid áttekintése:
 - **Demográfiai jellemzők:** region, tenure, age, marital, income, ed (iskolai végzettség), employ, retire, gender, reside
 - **Szolgáltatási előzmények:** tollfree, equip, callcard, wireless
 - **Szolgáltatások havidíjai és összesített díjak:** longmon, tollmon, equipmon, cardmon, wiremon, longten, tollten, stb.
 - **Szolgáltatási opciók:** multiline, voice, pager, internet, callid, callwait, forward, confer, ebill
 - **Ügyfél kategória:** custcat
- **Célváltozó:** churn . A churn (0 = nem hagyta el, 1 = elhagyta a szolgáltatást) bináris célváltozót szeretnénk prediktálni.

Klasszifikációs feladat

- Végig kommentelje a megoldást!
- Néhány szempont az elemzéshez:
 - Vizsgáljuk át az adathalmaz az adattisztítási szempontok szerint (hiányzó értékek, duplikációk, típuskonverziók). Ahol szükséges javítson az adatokon.
 - Szűrjük ki a outlier adatokat. Ha szükséges a kategóriaváltozókat alakítsuk numerikussá.
 - Vizsgáljuk meg, hogy a függő változók között van-e multikollinearitás. Ha van töröljük ki azok közül.
 - Standardizáljunk, majd bontsuk szét adatokat tanuló és tesztelő halmazra.
 - Illesszünk következő modelleket a tanuló adatokra (csak az sklearn-t kell használni):
 - Döntési fa
 - Véletlen erdő
 - GBM
 - Neutrális háló
 - Próbáljuk ki a modelleket tesztelő adatokon is.
 - Javítsunk a modelleken.
 - Értékelje a modelleket egy táblázatban. (accuracy, recall, AUC)
 - A legjobb modellnél írassa ki, hogy mekkora a valószínűsége, hogy az egyes ügyfelek lemorzsolódnak.
- Fájl : telco.csv